

# Modelos ARIMA

Gustavo A. García

[ggarci24@eafit.edu.co](mailto:ggarci24@eafit.edu.co)

Econometría II

Programa de Economía

Universidad EAFIT

Link slides en formato **html**

Link slides en formato **PDF**

## En este tema

- Introducción
- El enfoque Box-Jenkins
- Ejercicio aplicado en R: tasa de desempleo de los Estados Unidos

# Lecturas

- Maddala, GS. y Lahiri, K. (2009). *Introduction to econometrics*. 4a edición, Willey. [Cap 13](#)
- Enders, W. (2014). *Applied econometric time series*. 4th edition, Wiley. [Cap 2, sección 8](#)
- Pfaff, B. (2008). *Analysis integrated and cointegrated series with R*. 2th edition, Springer. [Part I, sección 1.4](#)
- Hyndman, R.J., y Athanasopoulos, G. (2021). *Forecasting: principles and practice*, 3rd edition, OTexts: Melbourne, Australia.

## Páginas webs

- <https://finnstats.com/index.php/2021/04/26/timeseries-analysis-in-r/>

# Introducción

- Hemos estudiado cómo una serie de tiempo puede ser explicada o bien por su historia ( $AR(p)$ ) o por choques contemporáneos o pasados ( $MA(q)$ )
- También estudiamos que estos dos procesos pueden ponerse juntos en un proceso más general  $ARMA(p,q)$
- Ahora estudiaremos brevemente los modelos  $ARIMA$  o el enfoque de Box-Jenkins para series de tiempo
- Este enfoque consiste en tres etapas:
  1. identificación
  2. estimación
  3. diagnóstico

# El enfoque Box-Jenkins

- El enfoque de Box-Jenkins (BJ) es una de las metodologías más amplias para el análisis de las series de tiempo
- Los pasos básicos de la metodología BJ son:
  1. diferenciar la serie, de modo que se alcance la estacionariedad
  2. identificar un modelo tentativo
  3. estimar el modelo
  4. verificar el diagnóstico (si se encuentra que el modelo es inadecuado, volver al paso 2)
  5. usar el modelo para pronosticar

# El enfoque Box-Jenkins

## Primer paso

- Determinar si la series es estacionaria
  - correlograma
  - test de raíces unitarias
- Si la serie no es estacionaria deferenciarla (cuantas veces sea necesario) para logra su estacionariedad

## Segundo paso

- Examinar el correlograma de la serie estacionaria para decidir los ordenes apropiados de los componentes AR y MA

## Tercer paso

- Estimación del modelo ARMA

## Cuarto paso

- Verificación del diagnóstico para comprobar la ideonidad del modelo tentativo

## Quinto paso


- Realizar el pronóstico con el modelo ARIMA

# Ejercicio aplicado en R: tasa de desempleo de los Estados Unidos


```
library(urca); library(tidyverse); library(forecast); library(stats); library(lmtest)
data(nnext)
```

```
y <- ts(na.omit(nnext$unemploy), start=1909, end=1988, frequency = 1)
```

```
ts.plot(y, main = "Log tasas de desempleo US (media = 1.72)", xlab = "Año",
abline(h = mean(y), col = "red", lwd = 3))
```



```
ts.plot(diff(y), main = "Primera diferencia Log tasas de desempleo US", xlab = "Año",
abline(h = 0, col = "red", lwd = 3))
```



Parece preferible trabajar con la serie sin diferenciar:


- La serie en log no tiene tendencia
- Existe buena cantidad de persistencia, en el sentido que las duraciones cuando el diferencial está por encima o por debajo de la media son algo largas
- La dinámica de la serie parece ser constante sobre la media
- Cuando se hace el Dickey-Fuller indica que la serie es estacionaria
- Parece que la serie es estacionaria en covarianza
- La serie diferenciada es muy errática y podría tener poco contenido informativo para hacer predicción de valores futuros




# Ejercicio aplicado en R: tasa de desempleo de los Estados Unidos

Ahora calculamos el correlograma de la serie

```
ggAcf(y, main="Función AC log tasa de desempleo", ylab="AC")
```



```
ggPacf(y, main="Función PAC log tasa de desempleo", ylab="PAC")
```



Parece ser un proceso ARMA(2,0). Estimemos también un proceso sobreparametrizado ARMA(3,0) y pongamos a competir los dos procesos

# Ejercicio aplicado en R: tasa de desempleo de los Estados Unidos

```
arma20 <- arima(y, order=c(2,0,0))
arma20
```

Call:

```
arima(x = y, order = c(2, 0, 0))
```

Coefficients:

	ar1	ar2	intercept
	0.9297	-0.2356	1.6988
s.e.	0.1079	0.1077	0.1586

sigma^2 estimated as 0.195: log likelihood = -48.59, aic = 105.18

```
coeftest(arma20)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )
ar1	0.92970	0.10786	8.6197	< 2e-16 ***
ar2	-0.23560	0.10771	-2.1874	0.02872 *
intercept	1.69883	0.15860	10.7116	< 2e-16 ***

---


Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Los parámetros estimados son estadísticamente significativos y los valores satisfacen la condición de estabilidad ( $|\rho| < 1$ )


# Ejercicio aplicado en R: tasa de desempleo de los Estados Unidos

Ahora pasamos a chequear los residuales del modelo

```
res20 <- residuals(arma20)
ggAcf(res20, main="Función AC de los residuales", ylab="AC")
```



```
ggPacf(res20, main="Función PAC de los residuales", ylab="PAC")
```



```
Box.test(res20, lag = 1, type = "Ljung-Box")
```

Box-Ljung test

data: res20  
X-squared = 0.1797, df = 1, p-value = 0.6716

```
shapiro.test(res20)
```

Shapiro-Wilk normality test

data: res20  
W = 0.99313, p-value = 0.9501

Se tiene que los residuales no están correlacionados y se distribuyen normal

# Ejercicio aplicado en R: tasa de desempleo de los Estados Unidos

Comparemos con el modelo sobreparametrizado ARMA(3,0)

```
arma30 <- arima(y, order=c(3,0,0))
arma30
```

```
coeftest(arma30)
```

```
Call:
arima(x = y, order = c(3, 0, 0))
```

Coefficients:

	ar1	ar2	ar3	intercept
	0.9727	-0.3949	0.1669	1.6863
s.e.	0.1101	0.1495	0.1103	0.1851

sigma^2 estimated as 0.1893: log likelihood = -47.47, aic = 104.93

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )	
ar1	0.97271	0.11013	8.8322	< 2.2e-16	***
ar2	-0.39486	0.14954	-2.6405	0.008279	**
ar3	0.16690	0.11031	1.5130	0.130286	
intercept	1.68631	0.18511	9.1097	< 2.2e-16	***

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

- Se observa que los coeficientes del primer y segundo rezago son similares al modelo ARMA(2,0), pero el tercer rezago no es estadísticamente diferente de cero
- Comparando el AIC (el mejor modelo es que tenga menor valor), ARMA(3,0) es mejor que ARMA(2,0)
- Un test likelihood-ratio puede calcularse para seleccionar el mejor modelo ( $H_0$ : se prefiere el modelo restringido (ARMA(2,0)))

```
lrtest <- as.numeric(2*(logLik(arma30)-logLik(arma20)))
pchisq(lrtest, df=1, lower.tail = F)
```

```
[1] 0.1336066
```

Esto indica no rechazar  $H_0$ , es decir que las mejoras en el log-likelihood no son significantes de pasar de un modelo ARMA(2,0) a ARMA(3,0), por lo que se prefiere el modelo más parsimonioso ARMA(2,0)

# Ejercicio aplicado en R: tasa de desempleo de los Estados Unidos

Una vez se ha estimado un modelo ARMA, puede ser usado para predecir valores futuros de la variable de interes

Estas predicciones pueden ser calculadas recursivamente desde el predictor lineal

$$Y_T(h) = \rho_1 \bar{Y}_{T+h-1} + \dots + \rho_p \bar{Y}_{T+h-p} + \epsilon_t + \theta_1 \epsilon_{t-T-1} + \dots + \epsilon_{t-T-q}$$

donde  $\bar{Y}_t = Y_t$  para  $t \leq T$  y  $\bar{Y}_{T+j} = Y_T(j)$  para  $j = 1, \dots, h-1$

Este predictor es equivalente a

$$Y_T(h) = \mu + \psi_h \epsilon_t + \psi_{h+1} \epsilon_{t-1} + \psi_{h+2} \epsilon_{t-2} + \dots$$


Cuando el horizonte de predicción  $h$  es mayor que el orden  $q$  del MA, la predicción son determinandas sólo por los términos autorregresivos

# Ejercicio aplicado en R: tasa de desempleo de los Estados Unidos

Vamos a predecir 10 años de la tasa de desempleo

```
arma20.pred <- predict(arma20, n.ahead = 10)
predict <- ts(c(rep(NA, length(y) - 1), y[length(y)]), arma20.pred$pred), start=1909, frequency = 1)
upper <- ts(c(rep(NA, length(y) - 1), y[length(y)]), arma20.pred$pred + 2*arma20.pred$se), start = 1909, frequency = 1)
lower <- ts(c(rep(NA, length(y) - 1), y[length(y)]), arma20.pred$pred-2*arma20.pred$se), start = 1909, frequency = 1)
observed <- ts(c(y, rep(NA, 10)), start = 1909, frequency = 1)

data <- data.frame(year = 1909:1998, actual = observed, predicho = predict, ic_l = lower, ic_u = upper)
ggplot(data) +
  geom_line(aes(x = year, y = actual, color = "Observada"), linewidth = 1.5) +
  geom_line(aes(x = year, y = predicho, color = "Predicha"), linewidth = 1.5) + geom_ribbon(aes(x = year, y = predicho, ymin = ic_l, ymax = ic_u, fill = "IC 95%")) +
  theme(legend.text = element_text(size = 20), text = element_text(size=16), legend.spacing.y = unit(-0.4, "cm"), legend.background=element_blank()) +
```



# Ejercicio aplicado en R: tasa de desempleo de los Estados Unidos

Existe otra función más poderosa que selecciona el mejor modelo ARIMA

```
arma_op <- auto.arima(y)
arma_op
```

Series: y  
ARIMA(1,0,1) with non-zero mean

Coefficients:

	ar1	ma1	mean
	0.5272	0.5487	1.6934
s.e.	0.1221	0.1456	0.1546

$\sigma^2 = 0.1917$ : log likelihood = -46.51  
AIC=101.01 AICc=101.55 BIC=110.54

```
coeftest(arma_op)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )
ar1	0.52717	0.12213	4.3166	1.585e-05 ***
ma1	0.54866	0.14558	3.7687	0.0001641 ***
intercept	1.69340	0.15461	10.9526	< 2.2e-16 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

```
f <- forecast(arma_op, 10, 95)
autoplot(f, main="Predicción de la tasa de desempleo")
```

